Inteligência Computacional

Diabetes Classification

Pedro Augusto Gontijo Moura
João Pedro Rodrigues Silva

CEFET-MG - Divinópolis

Março 2026

Contextualização do Problema

Segundo José Antonio Miguel Marcondes (2003):

- Diabetes afeta milhões de brasileiros
- Crescimento do tipo 2

Logo, denota-se:

- Apoio ao diagnóstico com dados
- Importância na prevenção

Natureza da Base de Dados

Este trabalho, utiliza-se da base pública Diabetes Health Indicators Dataset (Kaggle) que possui:

- **100.000 registros**
- **31 atributos**
- Dados clínicos, sociais e comportamentais
- Classificação binária (0 ou 1)
- Proporção de 60% positivos

Pré-processamento

Com base nas dificuldades que serão apresentadas posteriormente, necessitou-se da aplicação de etapas de pré-processamento, dentre elas:

- Codificação com OneHotEncoder
- Amostragem e divisão estratificada
- Normalização (KNN e SVM)
- Seleção de atributos (Random Forest)

Atributos Relevantes

Para atender ao enunciado sem inflar a quantidade de artefatos, foi implementada uma EDA mínima com um resumo tabular da base e um gráfico de distribuição da classe-alvo.

- **hba1c** – média da glicose no sangue nos últimos meses
- **glucose_postprandial** – glicose após refeições
- **glucose_fasting** – glicose em jejum

Insight

Fortemente ligados ao diagnóstico clínico

Metodologia Experimental

- **Avaliação conduzida sob um protocolo padronizado**
  - Mesma base de dados
  - Mesma divisão treino/teste (80/20)
  - Mesmo fluxo de pré-processamento
- **Utilização de pipelines**
  - Integração de pré-processamento e modelagem
  - Evita vazamento de dados
  - Garante consistência entre os modelos
- **Métricas de avaliação**
  - Accuracy Precision Recall F1-score

Objetivo

Garantir uma comparação justa, consistente e reprodutível entre os modelos

Validação e Robustez

- **Validação cruzada estratificada (5 folds)**
  - Divisão dos dados em 5 subconjuntos
  - Preserva a proporção entre as classes em cada fold
- **Múltiplas execuções do experimento**
  - 3 repetições com seeds diferentes
  - Reduz influência de uma única divisão dos dados
- **Agregação dos resultados**
  - Métricas finais obtidas pela média das execuções
  - Maior estabilidade e confiabilidade nos resultados

Objetivo

Garantir maior **robustez**, **estabilidade** e **confiabilidade** na avaliação dos modelos

CEFET-MG

Algoritmos Avaliados

- **KNN (K-Nearest Neighbors)**
  - Classifica com base nos vizinhos mais próximos
  - Simples e intuitivo
- **SVM (Support Vector Machine)**
  - Busca o hiperplano que melhor separa as classes
  - Eficiente em espaços de alta dimensão
- **Decision Tree**
  - Baseada em regras de decisão (estrutura em árvore)
  - Fácil interpretação dos resultados

Resultados

Modelo	F1	Accuracy	Recall
SVM	**0.8858**	**0.8680**	0.8544
Decision Tree	0.8800	0.8543	**0.8900**
KNN	0.8376	0.8063	0.8328

- **SVM**: melhor desempenho geral
- **Decision Tree**: maior recall

Resultados

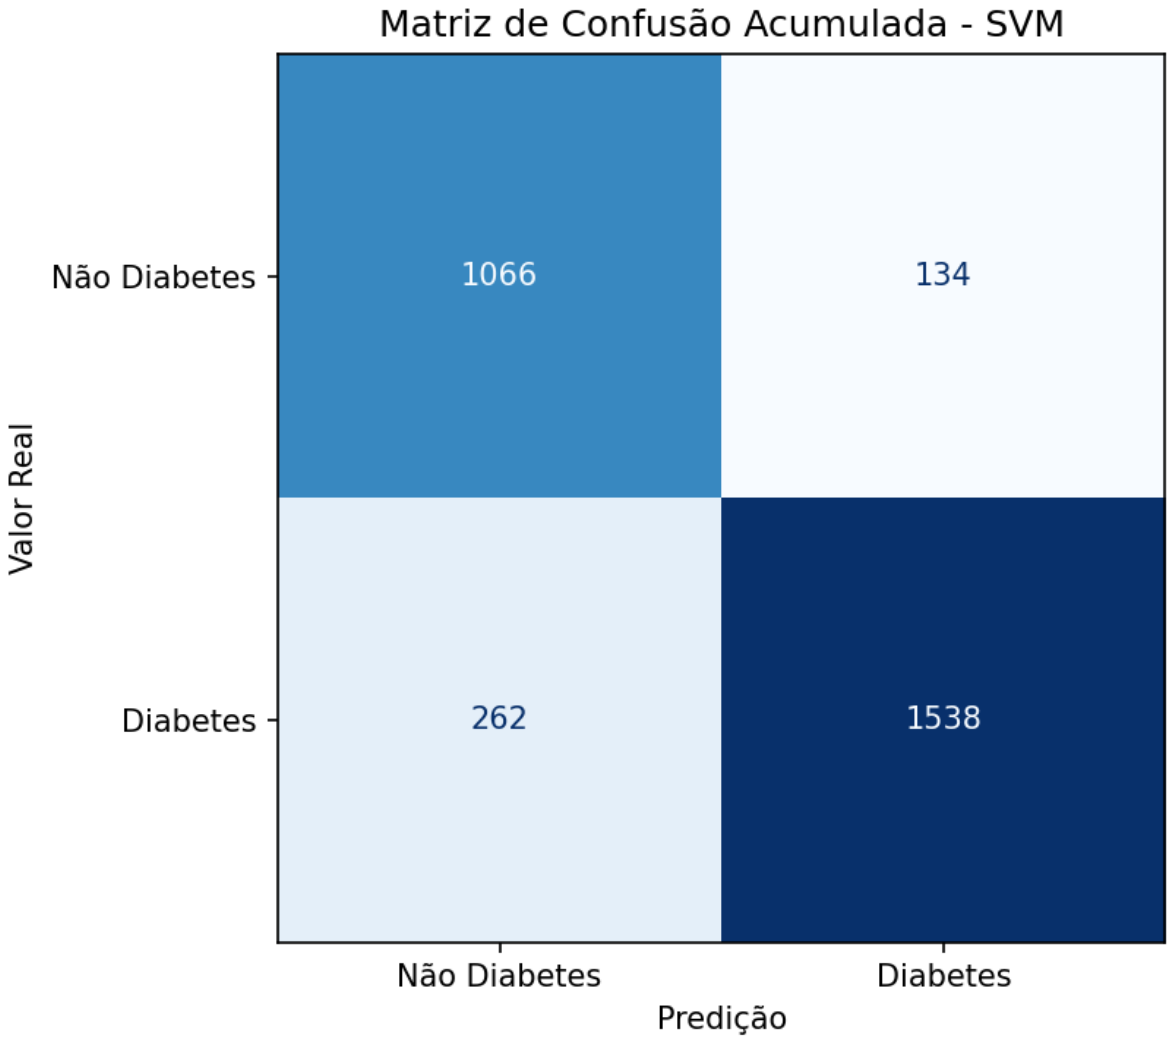

Figura: Matriz de Confusão (SVM)

Discussão

- **SVM** apresentou o melhor desempenho geral, com maior **F1-score** e **accuracy**, indicando bom equilíbrio entre precisão e recall.
- **Decision Tree** obteve maior **recall**, sendo mais eficiente na detecção de casos positivos, porém com leve perda em precisão.
- **KNN** apresentou desempenho inferior, possivelmente devido à sensibilidade à escala e à distribuição dos dados no espaço de atributos.
- Existe um **trade-off entre precision e recall**:
  - Maior recall $\Rightarrow$ menos falsos negativos
  - Maior precision $\Rightarrow$ menos falsos positivos
- A escolha do modelo depende do objetivo:
  - Diagnóstico precoce $\Rightarrow$ priorizar recall
  - Evitar alarmes falsos $\Rightarrow$ priorizar precision

Conclusão

- Modelos eficazes
- Importância da metodologia
- **F1-score como métrica principal**

Resultados confiáveis com metodologia robusta

Referências

- MARCONDES, José Antonio Miguel. *Diabete melito: fisiopatologia e tratamento*. Revista da Faculdade de Ciências Médicas de Sorocaba, v. 5, n. 1, p. 18–26, 2007. Disponível em: `https://revistas.pucsp.br/index.php/RFCMS/article/view/117`. Acesso em: 24 mar. 2026.

- KOLIPAKA, Rakesh; DIGUTLA, Ranjith Kumar. *Diabetes Health Indicators Dataset*. Kaggle, 2025. Disponível em: `https://doi.org/10.34740/KAGGLE/DSV/13128284`.